

AWS Kiro- 프롬프트만으로 논문 투고 해보기

Human-in-the-Loop Auto Research

김진욱

한양대학교 데이터사이언스 전공



Agenda

- AWS Kiro란?
- 프로젝트를 하게 된 계기
- 연구 과정
- 후기

AWS Kiro란?

Spec-driven Development


Kiro - AWS에서 VSCODE를 포크하여 만든 에이전트 기반 통합 개발 환경

- 자연어 요구사항을 바로 코드로 구현하지 않고,
Requirements → Design → Tasks 단계로 구조화한 뒤 개발을 진행한다.
- 요구사항과 설계, 구현 작업을 명세로 남겨 AI가 프로젝트의 목적과 제약을 지속적으로 참고할 수 있도록 한다.
- 복잡하거나 장기적인 개발에서는 명세를 기준으로 구현과 수정을 반복해 **요구사항 누락과 개발 방향의 흔들림을 줄인다.**

Kiro - 개발 의도를 명세로 구조화한 뒤 구현하게 하는 Spec-driven 개발 환경



Kiro 세부구성



Kiro 세부구성 – Kiro 탭

- SPECS :

자연어 요구 사항을 요구사항 → 설계 → 구현작업으로 구조화해 개발 계획을 만든다.
ex : requirements.md, design.md, task.md 생성

- AGENT HOOKS :


특정 이벤트가 발생하면 테스트·문서화·코드 검사 등의 작업을 자동 실행
ex : 파일 저장 후 자동 테스트 실행

- AGENT STEERING & SKILLS :

에이전트가 따라야 할 프로젝트 규칙과 반복 가능한 작업 절차를 정의
Steering = 상시 규칙 / Skills = 작업별 매뉴얼


- MCP SERVERS :

에이전트를 외부 도구와 데이터 소스에 연결해 IDE 밖의 정보와 기능까지 활용하게 합니다.
ex: GitHub, Jira, DB, AWS 문서 등




Kiro 세부구성 – Powers 탭

- Powers:
특정 기술의 도구·지식·작업 절차를 하나의 패키지로 설치하고,
필요한 상황에서만 동적으로 활성화.



Kiro 세부구성 – Session 탭


- **SPEC:**
Requirements → Design → Tasks 순서로 문서를 만들고, 각 단계에서 사용자가 내용을 확인·승인 한 뒤 다음 단계로 넘어간다.
- **Quick Spec:**
사용자의 승인을 받지 않고 최소한의 대화 만으로 빠르게 requirements.md, design.md, tasks.md를 생성하여 다음 단계로 넘어간다.
- **Bug Fix:**
버그 재현 → 원인 분석 → 수정 설계 → 회귀 방지 → 구현 작업 순서로 접근하여 고쳐야 하는 것과 보존해야 하는 것을 명확히 한 다음 디버깅을 진행한다.
- **Plan:**
읽기전용모드. 현재까지 진행된 내용을 바탕으로 앞으로의 방향성을 계획할때 사용.



연구배경

Human-in-the-Loop AutoResearch를 하게 된 계기

26년 4월, Hacker News에서 아마추어 수학자가 GPT PRO로 수학 난제를 푼 게 화제가 됨.




Liam Price just cracked a 60-year-old problem that world-class mathematicians have tried and failed to solve. He's 23 years old and has no advanced mathematics training. What he does have is a ChatGPT Pro subscription, which gives him access to the latest large language models from OpenAI.

Hacker News:


https://news.ycombinator.com/item?id=47903126&utm_source=chatgpt.com

수학자의 Chat GPT 대화 로그:


<https://chatgpt.com/share/69dd1c83-b164-8385-bf2e-8533e9baba9c>



개별 문제 해결 사례를 넘어, 연구 프로세스를 자동화 및 가속화하는 흐름이 계속해서 나타나고 있다보니 AI를 단순히 과제나 공부하는 데에만 쓰기에는 아깝다는 생각이 점차 들었음.



△ Andrej Karpath – Auto research
가설 생성 → 코드 수정 → 실험 → 평가의 자동화



△ 연구 가속화: OpenAI 내부의 모습
Codex를 활용하여 연구원들이 더 많은 실험을 수행하고 있음.

프로젝트 수행 배경 : START AWS에서 지원받은 Kiro Power를 연구 프로젝트에 사용하기로 결정.



7월 23일 목요일 ▾

오후 1:14

이제 Kiro 하나만 구독하면 모든 모델을 다 쓸 수 있는데요.
필요하신 분 선착순으로 n명(제 마음)을 뽑아 200불 멤버십을 8월까지 지원해 드립니다.
조건은 후기 입니다.

kiro.dev/blog/gpt-5-6

GPT-5.6 is now available in Kiro
 Kiro



❤️ 20

👤 13

👤 13

😊

3개의 댓글 2개월 전 마지막 댓글



Manage

Signed in with Github | [UserID](#) 🔗

Estimated Usage

resets on 08/01

Total credits used this month: 0

Credits 0 used / 10000 covered in plan

0%

Additional credits

You can have up to 5 add-on credit packs at a time.



Buy credits on your terms
We've moved to add-on credits so you can purchase what you need, when you need it.
No surprise charges at the end of the month.

START AWS는 최신 IT 정보, 해커톤 및 네트워킹 정보, 이벤트 등이 제공되는 대학생 AWS 기술 커뮤니티임.





김진욱 Human-in-the-Loop Auto Research



연구과정

주제선정부터 Paper 제작까지

연구 주제 : 딥러닝의 최적화 과정에서 경사하강법 대신 Newton Method를 쓰면 어떨까
Newton Method는 연산량이 매우 커서 딥러닝 최적화에는 잘 쓰이지 않음.



Arxiv에 Submission 하는 것을 목표로 실험을 진행함.

ChatGPT 딥리서치를 활용하여 Kiro에게 전달할 명세서를 제작.

딥러닝 역전파에서 GD 말고 뉴턴 메소드를 쓰고 싶은데, Hessian 역행렬 연산이 병목이 잦아. 행렬의 역행렬 연산 최적화 기법을 탐구해줘.
🔗 심층 리서치

리서치 완료까지 10m · 인용 35개 · 검색 423건

딥러닝 뉴턴 최적화에서 Hessian 역산 병목을 해소하는 행렬 최적화 기법

딥러닝 뉴턴 최적화에서 Hessian 역산 병목을 해소하는 행렬 최적화 기법

Executive summary

딥러닝 학습에서 경사하강법을 뉴턴법으로 대체하려 할 때 핵심 문제는 역행렬 자체라기보다, 파라미터 수를 (P)라 할 때 (P\times P) Hessian을 생성·저장·통신하고 선형계

[$(H + \lambda I)p = -g$]

를 반복해서 푸는 전체 과정이다. 밀집 Hessian은 $O(P^2)$ 메모리, 직접 분해는 $O(P^3)$ 시간을 요구한다. FP32로 $(P=10^6)$ 인 모델의 Hessian만 약 4 TB이고, $(P=10^8)$ 이면 약 40 PB이며, $(P=10^9)$ 이면 약 4 EB이다. 따라서 수백만 파라미터 이상에서는 “Hessian 역행렬을 빠르게 계산”하는 문제를 그대로 풀기보다, **역행렬을 형성하지 않고 선형계만 풀거나, 곱셈 구조를 제한하거나, Hessian-vector product만 사용하는 방향으로 문제를 재정의해야 한다.** Hessian-free 계열도 이러한 관점에서 역행렬과 곱셈행렬 형성을 모두 피하고 conjugate gradient(CG)로 뉴턴 방정식을 근사적으로 푼다.

가장 중요한 실험 결과는 다음과 같다.

그러면 너가 작성해준 보고서와 함께, 코딩 에이전트에게 넘길 실험이 주제나 이런것들에 대한 README.md를 작성해줘.

2m 55s 동안 처리함

코딩 에이전트가 바로 구현을 시작할 수 있도록 다음 내용을 포함한 README.md 를 작성했습니다.

- 연구 주제·가설·핵심 연구 질문
- Fixed / Heuristic / RL-Controlled Newton-CG 비교
- RL 상태·행동·보상·에피소드 정의
- HVP-CG-negative curvature-fallback 구현 요구사항
- 8GB VRAM 기준 MNIST → Fashion-MNIST → CIFAR-10 단계별 실험
- AdamW-SGD를 포함한 baseline과 공정한 비교 기준
- Ablation study와 일반화 실험
- 권장 저장소 구조·설정 파일·CLI·로그 스키마
- 코딩 에이전트용 6개 Milestone과 완료 조건
- 실패 가능성까지 연구 결과로 해석하는 기준

보고서는 저장소에서 docs/hessian_inverse_report.md 에 배치하는 것으로 가정했습니다.

README.md
문서



Research WorkFlow :

나의 개입을 최소화(Arxiv 등록 목적, 실험의 재현성)한 다음 ChatGPT가 전반적인 실험의 방향성을 잡고, Kiro가 이를 코드로 구현함



실험의 재현성 보장, LaTeX로 PDF 빌드, Latex 및 재현용 실험 코드를 위한 공개 레포지토리.



권장 순서

1. AGGREGATION_VERSION=3과 3층 보고를 clean commit
2. delta 0인 정확한 spec 확인
3. action-trajectory가 실제 동일인지 검증
4. easy-regime 동물이면 유효 결과로 기록
5. ill-conditioned 동물이면 planner/action-space 진단
6. 기존 dev set은 유지
7. 필요하면 별도 challenge set만 사전 등록
8. 예정대로 beam 8 실행

따라서 1번 진단이 우선이지만, 현재 코드를 먼저 커밋하세요. 그리고 delta 0이 SPD spec에서 나온다면 이를 제거할 이유는 없습니다. 오히려 "adaptive control은 모든 문제에서 필요한 것이 아니라 conditioning이 나쁜 regime에서만 가치가 생길 수 있다"는 프로젝트의 핵심 결과가 될 수 있습니다.

먼저 커밋하겠습니다. 커밋했습니다. 이제 spec별 진단 스크립트를 만들겠습니다. 원인이 확정됐고, 예상과 다릅니다. 'quad_spd' delta 0은 동일한 선택 때문이 아니라 D14 floor 때문입니다.

진단 결과

spec	n	median	Δ	양수	0	음수
quad_ill_conditioned_d100_k1e+05	3	+0.5417	2	0	1	
quad_spd_d64_k1e+02	3	0.0000	0	3	0	
rosen_d2_s100_std	3	0.0000	0	3	0	



실제 진행 과정

Kiro의 진행보고에 대해서 다음 방향을 제시하는 GPT

리뷰어 지침을 반영합니다. 먼저 정정 전 수치가 문서에 남아 있는지 전수 검사합니다.outline.md와 저장된 summary에 구 수치가 남아 있습니다. summary는 캐시 재집계로 다시 씁니다.config_hash가 바뀌어 960 run을 재실행하려 합니다. 중단합니다 — meta에 acceptance_loss를 무조건 넣은 게 원인입니다.held-out을 다시 돌립니다. 해시가 복원되어 960 run 전부 캐시에서 재사용됩니다.캐시 재사용으로 즉시 진행됩니다. 그동안 draft를 리뷰어 지침대로 수정합니다.\$12를 과학적 결론과 프로젝트 결정으로 분리하고 Discussion을 추가합니다.E10과 provenance 문구를 리뷰어 지침대로 교체하고 절 번호를 정리합니다.Summary가 재생성됐는지 확인하고 그림 생성 스크립트를 만듭니다.Track T 구간에서 진행 중입니다. 대기하면서 그림 스크립트를 작성합니다.matplotlib이 있습니다. held-out 재집계 원료를 확인하고 그림을 생성합니다.raw가 960 → 1104로 늘었습니다. 캐시가 안 맞는 run이 있습니다. 무엇인지 확인합니다.Track T만 재실행되고 있습니다. 원인은 제가 TARGETS에 micro_neural을 추가한 것입니다 — **D13이 막으려던 바로 그 실패**입니다.targets payload가 이 run과 관련한 task 종류까지 담습니다. 실제 쓰는 것만 넣도록 고칩니다.raw는 gitignore 대상이라 git 복원이 안 됩니다. 재실행분을 제거해 원본 960으로 되돌립니다. 원본 960으로 복원했습니다 수정한 것처럼 ...

더 보기 ▾

지금 상태는 원고 공개 전 마지막 검증 단계입니다. 보고해준 수정들을 보면, 과대주장보다 오히려 파생 통계-정제성-재현성 오류를 끝까지 찾아 제거한 점이 이 프로젝트의 가장 강한 부분이 됐습니다.

전체 판단

현재 논문의 중심 주장은 방어 가능합니다.

Hessian-free Newton-CG에서 상태별 계산 자원 제어를 계획 문제를 구성했으며, 결정론적 quadratic의 held-out 평가에서는 다단계 lookahead가 고정 설정과 one-step greedy보다 개선됐지만, committed plan 대비 feedback replanning의 실용적으로 큰 추가 이득은 관측되지 않았다. 모델 불일치가 있는 stochastic regime에서는 replanning이 stale plan의 손해를 줄였지만 저비용 one-step controller를 안정적으로 능가하지 못했다.

이 문장이 원고 전체의 기준점이 되어야 합니다.

실험을 구현하는 Kiro

결론

- three_layer에 primary 포화 수를 출력하는 수정은 바로 진행
- rosen_d2 새외를 primary라고 부르는 정의는 폐기
- drop_saturated_pairs는 민감도 분석으로만 사용
- 기존 dev set은 보존
- 어려운 challenge set을 별도로 추가
- Beam 8은 challenge set까지 포함해서 판단

지금 발견은 프로젝트에 나쁜 소식이라기보다, 현재 benchmark의 3분의 2가 너무 쉬워 연구 가치를 측정하지 못한다는 사실을 확인한 것입니다. 알고리즘 실패와 측정 도구의 포화를 구분해냈다는 점에서 중요한 진전입니다.

Kiro

3층 보고를 재정의하겠습니다. primary 명칭을 폐기하고 포화 상태를 전부 출력합니다.

split_by_task_family가 이제 진단 표에만 쓰이니 사용처를 확인하고 재집계합니다. 파이프가 파서에 걸립니다. 단일 명령으로 실행합니다. 3층 보고가 그림을 완전히 드러냈습니다. spec별 분해가 결정적입니다.

spec별 결과 (beam 4, shrinking Q4 narrow)




text	vs best_static	vs C0(onestep)	v
quad_ill_conditioned_d100_k1e+05	+0.494	[+0.737, +0.494, +0.072]	
quad_spd_d64_k1e+02	+0.000	[0, 0, 0]	
rosen_d2_s100_std	-5.422	[-5.422, -5.422, -5.422]	

측정 가능한 regime은 quad_ill_conditioned 하나입니다. 거기서는 세 비교 모두 양수입니다.

- vs best_static: +0.494 (3승 0패)
- vs C0: +0.542 (2승 1패)
- vs committed: +0.370 (3승 0패)

rosen_d2에서 새로 보인 것

Kiro가 논문에 실기 위해 만든 figure image



Input – 투입 된 것

- 주요 실험 기간 : 7일(8/1 ~ 8/7)
- 사용한 Kiro 크레딧 : 약 6000여개 (Kiro 플랜 기준으로 \$120에 달하는 크레딧 사용)
Kiro Pro : 1,000크레딧(20\$), Kiro Pro+ : 2,000 크레딧(\$40), Pro Max : 5,000 크레딧(\$100), Power : 10,000 크레딧(\$200). 초과 시 추가 크레딧 비용은 개당 \$0.04로 모든 요금제에서 동일
- 실험 진행 및 LaTeX 컴파일, 재현용 공개 저장소를 만들기 위해 총 306번의 커밋 진행

Output – 얻게 된 산출물

- LaTex로 빌드된 25 페이지 짜리 Paper :

제목 – 저자 – 소속 – 초록 – 본문 구조. AWS Kiro와 Chat GPT를 활용한 연구라는 것을 명시.

When Does Feedback Help?
Planning and Model Mismatch in Hessian-Free Newton Control

Jin-Uk Kim
Department of Data Science
Hanyang University
Seoul, Republic of Korea
jukim628@gmail.com

Abstract

We study the allocation of damping and conjugate-gradient (CG) effort in Hessian-free Newton-CG [14, 19] as a sequential decision problem, and ask whether the resulting benefit comes from multi-step planning or from execution-time state feedback.

Under a fixed budget of 150 gradient-equivalent units (GE) we compare, on the same ladder, a tuned constant setting, a resource-clock open-loop schedule, a one-step greedy controller, a planner that commits to a single plan formed at the initial state, and a planner that replans at every step. The configuration was fixed once on development seeds and measured on disjoint held-out seeds.

On 40 instances of ill-conditioned symmetric positive definite quadratics ($d = 100$, $\kappa \in [10^4, 10^5, 10^6, 10^8]$, ten held-out seeds each), multi-step lookahead improved over one-step greedy control by +0.456 nat (95% CI +0.254 to +0.720, $p < 0.0001$, 35/40 instances). On the same 40 instances, replanning during execution differed from the committed planner by +0.010 nat (95% CI -0.033 to +0.053, $p = 0.97$, 21/40). The confidence interval was narrow and included zero, and we did not observe a practically large feedback benefit.

As an exploratory extension we compared a micro-neural problem in a deterministic full-batch regime and in minibatch regimes, changing only the samples the optimizer observes for the same model and data ($n = 3$ per regime). In the minibatch regimes, holding a stale plan was costly and replanning reduced that cost, but the planner did not consistently outperform inexpensive one-step control. Policy learning was a predeclared conditional next stage; on this evidence we did not proceed to it.

1 Introduction

Truncated or inexact Newton methods solve the Newton system approximately with an iterative solver rather than forming the Hessian [7, 18, 19, 25]. Implementations that access curvature only through Hessian-vector products build on the exact product of Pearlmutter [20]; applications at deep-network scale are reported by Martens [14], Martens and Sutskever [15]. Practical performance depends strongly on two computational-resource decisions: the damping level and the per-step CG iteration budget.

Damping belongs to the Levenberg-Marquardt family of regularizers [12, 13] and is related to a trust-region radius [6, 25]. In Hessian-free optimization the damping update rule is reported to drive performance [14, 15]. Truncating the CG budget is the central design variable of inexact Newton methods [7, 19].

Attempts to adapt these two quantities during optimization rather than fixing them connect to the learned-optimizer literature [2, 3, 16, 17]. For reinforcement learning [23] to be the right tool

Solver	Final loss	$\ \nabla L\ $	Status
lbfgs	1.007485×10^{-6}	3.456×10^{-2}	not converged
newton	3.059391×10^{-32}	2.650×10^{-16}	converged
sgd	nan	—	failed

Had we used L-BFGS alone, $J_{\text{achievable}}$ would have been underestimated at roughly 28.3 nat. Results from a different initialization do not raise the ceiling. The controller always starts from the task's own initial point, so an optimum in another basin is not attainable. We record such results as diagnostics only. Starting from (0.9, ..., 0.9), Rosenbrock at $d = 5$ reaches the global minimum; feeding that value into L_{ref} inflates $J_{\text{achievable}}$ from 2.58 to 31.44, admitting a spec that is in fact trapped in a local minimum.

Planner-family controllers are excluded from the panel. Including them would leak planner results into spec selection.

5.3 Detecting duplicated seeds

Because initial loss values can coincide by chance, we also compare the starting-point vectors. This check revealed that the default configuration of Rosenbrock $d = 5$ did not randomize the starting point, so seeds 2, 3, and 4 produced the same instance. Twenty-four runs were bitwise identical in every column, and that diagnostic's nominal $n = 3$ was in fact $n = 1$.

5.4 Final eligibility conditions and verdicts

Condition
failure_rate = 0
Joint floor-hit rate $\leq 1/3$
Median $J_E \geq 1$ nat for every baseline
$J_{\text{achievable}} - \text{median } J_E \geq 3$ nat
Spread among converged reference solvers ≤ 0.5 nat
Each seed yields a genuinely different instance

Spec	Verdict	$J_{\text{achievable}}$	Limiting factor	Minimum margin
quad $d=100$, $\kappa=10^3$	accepted	31.44	numerical floor	13.71
quad $d=100$, $\kappa=10^4$	accepted	31.44	numerical floor	20.98
quad $d=100$, $\kappa=10^5$	accepted	31.44	numerical floor	21.88
quad $d=100$, $\kappa=10^6$	accepted	31.44	numerical floor	21.93
rosen $d=5$	rejected	1.82	critical point	-0.00
rosen $d=5$ (random start)	rejected	2.58	critical point	0.00
micro-neural full-batch	accepted	31.44	numerical floor	11.68
micro-neural minibatch	accepted	31.44	numerical floor	28.75

Table 1: Eligibility verdicts. The margin for the Rosenbrock family is exactly zero, so those seeds cannot discriminate between controllers. We do not interpret this as a failure of the method on nonlinear problems.

All numbers in this manuscript originate in docs/results_stage2.md, whose sources are pinned by the SHA-256 values in paper/evidence_map.md. The tables in paper/tables/ are generated by scripts/make_tables.py from the same raw records and the same median convention. Numbers are not edited by hand in this manuscript.

The result store skips completed runs. Because identity is separated into three layers, editing aggregation code or documentation does not cause the optimizer to rerun.

Privacy note

Hostnames in committed public artifacts were replaced with stable pseudonymous labels before public release. This sanitization did not modify experimental configurations, results, checksums of raw numerical records, or scientific conclusions.

Two repositories must be distinguished here.

Earlier hostnames remain in the private source repository's history. The public reproducibility repository is an allowlist export with independent Git history and contains only pseudonymous host identifiers.

The export tool refuses to run if a device name appears in any file it would publish, so the second sentence is checked mechanically rather than asserted.

AI-Assisted Research Disclosure

Claude Opus, accessed through Kiro, assisted with implementation, refactoring, test generation, experiment orchestration, and report generation. GPT-5.6 Sol, accessed through ChatGPT, assisted with methodological critique, confound analysis, claim calibration, and manuscript review. The human author formulated the research questions, approved protocol changes, verified the reported results, determined their interpretation, and assumes full responsibility for the work.

References

- Brandon Amos. Tutorial on amortized optimization. *Foundations and Trends in Machine Learning*, 2023. arXiv:2202.00665.
- Marcin Andrychowicz, Misha Denil, Sergio Gómez Colmenarejo, Matthew W. Hoffman, David Pfau, Tom Schaul, Brendan Shillingford, and Nando de Freitas. Learning to learn by gradient descent by gradient descent. In *Advances in Neural Information Processing Systems* 29, 2016.
- Juhan Bae, Paul Vicol, Jeff Z. HaoChen, and Roger Grosse. Amortized proximal optimization. In *Advances in Neural Information Processing Systems* 35, 2022.
- Dimitri P. Bertsekas. *Dynamic Programming and Optimal Control*, volume 1. Athena Scientific, Belmont, MA, 4 edition, 2017. ISBN 978-1-886529-43-4.
- Richard H. Byrd, Gillian M. Chin, Will Neveitt, and Jorge Nocedal. On the use of stochastic Hessian information in optimization methods for machine learning. *SIAM Journal on Optimization*, 21(3):977–995, 2011. doi: 10.1137/10079923X.
- Andrew R. Conn, Nicholas I. M. Gould, and Philippe L. Toint. *Trust-Region Methods*. MPS-SIAM Series on Optimization. SIAM, Philadelphia, PA, 2000. doi: 10.1137/1.9780898719857.

김진욱 Human-in-the-Loop Auto Research

19

Output – 얻게 된 산출물

- 2개의 저장소, 5개의 브랜치 : 실험용 코드, LaTeX 코드 등이 저장됨.

When Does Feedback Help?

Hessian-free Newton 제어에서의 planning 과 model mismatch

한국어 · [English](#)

Hessian-free Newton-CG 안에서 컨트롤러가 damping 과 conjugate-gradient 에산을 배분할 때, 그 이득이 planning 에서 오는지 **실험 중 feedback** 에서 오는지를 분석한 연구다. 코드, 행 단위 결과, 원고 소스가 모두 들어 있다.

문서의 지원, 이 프로젝트의 원고는 동료 심사를 받지 않은 기술보고서다. 구현, 실험, 원고 작성과 검토에 시의 도움을 받았다. 자세한 내용은 [신 활용 및 연구 과정](#)에 정리했다.

질문

Truncated-Newton의 성능은 두 개의 계산 자원 결정에 크게 좌우된다. damping 수준과 step 당 CG 반복 계산이다. 이것을 최적화 도중에 조절하는 것은 강화학습 문제처럼 보인다. 그러나 정책을 학습하기 전에 알아야 할 것이 있다. 그 이득이 어디서 나오는가.

	질문
Q1	좋은 행동 sequence 가 존재하는가?
Q2	실험 중 feedback 으로 그 sequence 를 수정할 가치가 있는가?

두 질문이 요구하는 산출물이 다르다. Q1 한 성립하면 필요한 것은 초기 상태에서 스케줄을 확정하는 예측기다. Q2 가 성립할 때 한 step 단위 feedback 정책이 정당화된다.

둘을 분리하기 위해 동일한 예산 150 gradient-equivalent unit (GE) 에서 컨트롤러 사다리로 비교한다.

실험 결과

open-loop 스케줄 → 1-step greedy → committed plan → 자동 계획

committed 는 초기 상태에서 계획 하나를 세우고 그대로 실행한다. shrinking 은 매 step 재계획한다. 둘은 같은 인스턴스에서 같은 예산을 보므로, 그 사이의 차이가 feedback 의 가치를 분리해 낸다.

세 가지 결과

$d = 100$, $\kappa \in \{1e3, 1e4, 1e5, 1e6\}$, regime 당 held-out seed 10개인 ill-conditioned SPD quadratic 40 인스턴스에서 측정했다.

- 이득의 대부분은 상태 의존적 제어에서 온다. 튜닝 상수에서 1-step greedy 제어로 옮기면 $+1.155 \text{ nat}$ (95% CI $+1.092 \sim +1.831$, $p < 0.0001$, 40/40 인스턴스).
- 다단계 planning 은 실패하지만 더 작은 증분을 더한다. 1-step 제어 대비 $+0.456 \text{ nat}$ (95% CI $+0.254 \sim +0.728$, $p < 0.0001$, 35/40).
- 실험 중 재계획은 여기서 거의 더하지 않는다. committed 계획 대비 $+0.010 \text{ nat}$ (95% CI $-0.033 \sim +0.053$, $p = 0.97$, 21/40). 구간이 좁고 0 을 포함한다. 실험적으로 큰 feedback 이득은 관측되지 않았다.

탐색적 확장에서는 모델과 데이터를 고정하고 optimizer 가 관측하는 표본만 바꿨다. minibatch 노이즈 아래에서 committed 계획은 취약해졌다. step 기억률이 0.00 에서 0.66 ~ 0.79 로 올랐고 최종 개선량이 튜닝 상수보다 낮아졌다. 재계획이 그 손실을 줄였지만, **기본 1-step 제어를 일관되게 이기지는 못했다**. 이 실험은 regime 당 $n = 3$ 이므로 부호와 방향만 보고하고 크게는 인용하지 않는다.

정책 학습(PPO)은 사전 선연된 조건부 다음 단계였다. 이 증거로는 진행하지 않았다. PPO 를 실행하지 않았고 따라서 실패하지도 않았다. 범위와 관계 참조.

Planning and feedback in Hessian-free Newton control

Hessian-free Newton-CG 에서 damping 과 CG 반복 에산을 최적화 도중 조절하는 것의 이득을 사다리로 분석한 실험 코드다.

핵심 질문은 성능 향상 여부가 아니라 그 향상이 어디서 오는가다.

상태 의존적 계산 자원 제어의 이득은 다단계 planning 에서 발생하는가, 실험 중 feedback 에서 발생하는가?

결과 요약

고정 예산 150 GE 에서 $d=100$ ill-conditioned quadratic 네 개 ($\kappa \in \{1e3, 1e4, 1e5, 1e6\}$) 를 썼다. 실험을 dev seed 에서 한 번 고정하고 분리된 held-out seed 40 인스턴스에서 측정했다.

튜닝 상수 대비 (paired median, n=40)	median	95% CI	p
자원 시계 open-loop 스케줄	+0.395	[+0.350, +0.476]	<0.0001
1-step greedy 제어	+1.155	[+1.092, +1.811]	<0.0001
초기 상태 고정 계획 (committed)	+2.090	[+1.532, +2.407]	<0.0001
매 step 재계획 (MPC)	+1.690	[+1.462, +2.368]	<0.0001

직접 측정된 증분	median	95% CI	p	양수
다단계 lookahead (MPC - 1-step)	+0.456	[+0.254, +0.720]	<0.0001	35/40
실험 중 재계획 (MPC - committed)	+0.010	[-0.033, +0.053]	0.97	21/40

다단계 lookahead 의 추가 가치는 확인됐다. 실험 중 재계획의 실험적으로 큰 이득은 관측되지 않았다.

위 표의 값을 서로 빼지 마라. 성별 사이의 median 은 선행이 아니다. committed 의 상수 대비 값이 MPC 보다 크지만 직접 측정된 MPC - committed 는 +0.010 이다.

docs/results_stage2.md 가 원본 결과에서 자동 생성되는 전체 표다.

우리가 주장하지 않는 것

"feedback 를 필요없다" / "효과는 e 있을 줄 알았다"

equivalence margin 을 사용 증명하지 않았다

"강화학습이 optimizer 정어에 실패한다"

결측을 학습하지 않았다, 측정한 것을 oracle planner 와 행동들 보냈다

"히든층이 condition number 이 크다 줄기/알고한다"

비대칭을 검증했다. 어느 방향의 대칭성도 주장하지 않는다

"학습률의 확률이 stochastic 확률보다 NDR 좋다"

GE 는 regime 내부에서와 compute-matched 다

전체 목록은 paper/claim_ledger.md 의 NOT SUPPORTED 절에 있다.

Branches

New branch

Overview Yours Active Stale All

Search branches...

Default

Branch	Updated	Check status	Behind	Ahead	Pull request
main	last month			Default	

Your branches

Branch	Updated	Check status	Behind	Ahead	Pull request
backup/privacy-note-800c4c1	last month		26	1	
arxiv/submission-v1	last month		21	1	
experiment/reproduction-package	last month		6	0	
paper/stage2-manuscript	last month		21	0	

Active branches

Branch	Updated	Check status	Behind	Ahead	Pull request
backup/privacy-note-800c4c1	last month		26	1	
arxiv/submission-v1	last month		21	1	
experiment/reproduction-package	last month		6	0	
paper/stage2-manuscript	last month		21	0	

후기

Auto Research 및 Kiro 사용 후기

ArXiv Endorsement

- 해당 결과를 학술적인 기록물로 남기고 싶어 ArXiv Submission을 진행하였으나, Endorsement 되지 않아 Submission Failed

Start Submission

You may pause in the submission process at any stage and return to your submission from your user page at <https://arxiv.org/user>

Verify Your Contact Information

First Name:	jin-uk
Last Name:	Kim
Title:	
Affiliation:	Hanyang University
E-mail:	juwinkim201@gmail.com

[Change User Information](#)

☐ I certify that the above information is correct.

! We must have current contact information, especially your email address. Verify your name and institutional affiliation: make sure that we've represented your first and last names correctly and that any accented characters are properly represented. Return to the registration form to update your information. If your e-mail address [juwinkim201@gmail.com](#) is no longer valid, then you must [change your E-mail address BEFORE](#) proceeding.

[Continue](#)

Submission Agreement

Read and accept the [Submission Agreement](#) (opens a new window) before proceeding.

☐ By submitting to arXiv I have read and accept the [Submission Agreement](#).

If you are under 18 years of age: Please ask an older co-author to submit the work. If that is not possible you must complete the [arXiv parent/guardian consent form](#) before proceeding.

Authorship

☐ I am submitting as an author of this article.

☐ I am not an author but have obtained pre-authorization from arXiv to submit as a [third-party submitter](#).

License Statement

All articles and source files posted on arXiv.org can be viewed and downloaded by anyone.

Please select the license you would like to use to make your content available. Your chosen license is irrevocable. For all licenses here, except CC-Zero, the original copyright holder retains ownership after posting on arXiv.

arXiv encourages open access and a liberal license for re-use of the paper. However, each situation is unique. Funders may require specific licenses. Journals have different policies regarding preprints, accepted manuscripts, embargo periods, and post-publication distribution. Please note that different versions of the work can have different licenses.

It is the submitter's responsibility to choose the appropriate license for their content and ensure that they have the right to submit the content. Need help? See [License Information](#).

☐ CC-BY: Creative Commons Attribution

☐ CC-BY-NC: Creative Commons Attribution-NonCommercial

☐ CC-BY-NC-SA: Creative Commons Attribution-NonCommercial-ShareAlike

☐ CC-BY-NC-ND: Creative Commons Attribution-NonCommercial-NoDerivs

☐ CC-BY-NC-SA: Creative Commons Attribution-NonCommercial-ShareAlike

☐ CC-BY-NC-ND: Creative Commons Attribution-NonCommercial-NoDerivs

☐ arXiv.org perpetual, non-exclusive license

☐ CC-Zero: No Rights Reserved

Archive and Subject Class

Please read the [category descriptions](#) carefully to ensure you select the best-fitting category for your submission. Failure to do so may significantly delay the listing of your submission, and creates additional work for our volunteer moderators.

juwinkim201 has registered as author to the groups cs and math.

If your desired submission archive does not appear below, or you wish to change any defaults, return to your [registration form](#) and make any necessary changes.

Choose a primary classification for this submission:

Choose archive: Choose Subject Class:

[Continue](#)

Start

>> Add Files >> Review Files >> Process >> Metadata >> Preview

Start Submission

Please certify user information (click the checkbox).

You are not endorsed for this archive. See [endorsement help](#) or [request endorsement](#)

ArXiv Endorsement Request

- 진행한 연구와 밀접한 분야의 해외 연구자 3분께 콜드 메일을 통해 Endorsement를 요청.

[arXiv cs.LG endorsement request] — undergraduate, cites Tutorial on Amortized Optimization ([arXiv cs.LG 추천 요청] — 학부생, "상각 최적화 에 대한 튜토리얼" 인용) External 받은편지함 x

김진욱 <jwkim628@hanyang.ac.kr>

2026. 8. 6. 오후 5:16 ☆ ☺ ↶ ⋮

Dear

I am an undergraduate in the Department of Data Science at Hanyang University, Seoul. I am requesting endorsement to submit my first arXiv preprint to cs.LG.

I am writing to you because my manuscript cites your Tutorial on Amortized Optimization when framing its follow-up direction, and because that framing is the part I would most want checked by someone who works on it.

The paper treats the allocation of damping and CG iteration budget inside Hessian-free Newton-CG as a sequential decision problem. Rather than training a policy first, I separated two questions: does a good action sequence exist, and is it worth revising that sequence with feedback during execution. Under a fixed 150 gradient-equivalent budget, on 40 held-out instances of ill-conditioned SPD quadratics ($d = 100$, four values of κ , ten held-out seeds each):

tuned constant -> one-step greedy	+1.155 nat (CI +1.092 to +1.811, 40/40)
one-step -> multi-step planner	+0.456 nat (CI +0.254 to +0.720, 35/40)
committed plan -> replanning	+0.010 nat (CI -0.033 to +0.053, 21/40)

A good multi-step sequence exists, and it can largely be determined at the initial state. That combination is why Section 12.4 points toward amortized prediction of a schedule from initial problem features rather than a per-step feedback policy, citing your tutorial for the framing and Bae et al. (2022) as the closest existing instance. I did not implement that direction and mention it only as future work.

I state the limits explicitly. The planner is an oracle diagnostic consuming 1,294x the deployment budget. The micro-neural extension is exploratory at $n = 3$, where I report signs rather than magnitudes. The results do not generalize to Hessian-free Newton methods as a family or to neural optimization in general. Gate thresholds were fixed before results were seen; on this evidence I did not proceed to the predeclared PPO stage, so PPO was not run and did not fail. Twelve protocol deviations and a benchmark design defect are documented rather than omitted. Section 15 includes a disclosure of AI-assisted work and my responsibility as the author.

Code, row-level results, and the reproduction path are public:
(tag arxiv-submission-v1)

The manuscript is attached. I understand endorsement is not peer review and concerns only whether the submission is appropriate for the category.

<https://arxiv.org/auth/endorse?x=>
Endorsement Code:

If you would rather not, no reply is needed. Thank you for your time.

Jin-Uk Kim
Department of Data Science, Hanyang University
jwkim628@gmail.com
jwkim628@hanyang.ac.kr

ArXiv Endorsement Request


- 한분께서 감사하게도 답장을 해주셨고, 연구 주제에 대한 긍정적인 답장을 받음.



ArXiv Endorsement Request

- 한분께서 감사하게도 답장을 해주셨고, 연구 주제에 대한 긍정적인 답장을 받음.

그러나, AI-generated한 느낌이 너무 많이 나고, 이러한 논문들로 인해 혼란이 많다는 이유로 Endorsement 받지 못했음.



Auto Research 후기

- ArXiv Submission 실패는, 실험을 진행하면서 어느 순간부터 내가 Kiro와 GPT가 하는 말을 이해하지 못한 상태로 에이전트에게 권한 승인만 해주고 있었기에 당연한 결과였음.

Article Submissions					
Update X Delete Unsubmit					
Identifier	Type	Title	Status	Actions	Expires
submit/7917812	New	Submission ID: 7917812	incomplete	Update X	2026-08-20
START NEW SUBMISSION Submit a new paper using our refreshed v1.5 system. What changed?					

- 이러한 점은 전문가의 평가에서 제대로 드러났음. 양식이 지켜진 25페이지의 Paper, 재현성이 확보된 공개 저장소까지 준비하였지만 진행 과정을 제대로 이해하지 못한채로 얻은 결과물은 “like it is too AI-generated”라는 평가를 받았음.

Thanks for reaching out! It is a nice space to be investigating in and the followups on amortization seem nice. The paper looks like it is **too AI-generated**. I cannot endorse it. I think the field is suffering a lot from too many AI-generated papers that create noise in the system. Being an undergraduate is a great time to connect with others at your university who can help you develop it into a more complete paper and disseminate it into the community. I know it can be harder at some schools than others but I hope you can find something there

Auto Research 후기 – 사람이 해야 했던 것

- AI가 잘했던 것


구현 · 반복 실험 · Figure 제작 · LaTeX · Github Repository 관리

- 사람이 해야 했던 것

결과물을 이해하고 해석하여 온전히 자기 것으로 만들고, 이를 글로 남기는 것

Research WorkFlow :

나의 개입을 최소화(Arxiv 등록 목적, 실험의 재현성)한 다음 ChatGPT가 전반적인 실험의 방향성을 잡고, Kiro가 이를 코드로 구현함



정작 Workflow에는 내가 연구를 이해하고 검증하는 단계가 없었다

AWS Kiro 사용 후기

[좋은 점]



- **GPT 5.6 Sol, Claude Opus 5 등 최신 프론티어 모델 중에서 원하는 모델로 작업을 진행 할 수 있음.**
 - ※ 26년 4월 Azure의 ChatGPT 독점이 만료됨에 따라 Kiro에서도 GPT 모델을 사용할 수 있게 되었음.
- **캘린더 월 기준 구독 방식 : 매달 1일에 한달 치 크레딧이 일괄 지급**
 - ▶ 복잡한 작업을 끊김 없이 진행 할 수 있음. & 월말에 가입하는 경우, 한달 치 크레딧을 적은 가격에 사용 할 수 있음



AWS Kiro 사용 후기

[아쉬운 점]

- 불안정한 Windows PowerShell 처리 능력 :
 - 자동으로 진행되어야 할 작업들이 잘못된 Kiro의 Powershell 커맨드로 인하여 세션이 끊기는 경우가 잦았음.
 - 요청을 다시 한번 해야하는 번거로움 존재.
- 반복적인 권한 Approval 요구:
 - 승인 관리가 손쉬운 Codex와 달리, Kiro가 요청 할 때 Approval을 해야함.
 - 자동으로 승인된 작업도 PowerShell 이슈로 다시 Approval 해줘야 되는 경우가 있었음.



AWS Kiro 총평

- 최신 프론티어 모델을 활용해 긴 작업을 끊임없이 수행할 수 있다는 점은 큰 장점.
 - 한 달치 크레딧을 일시불로 지급하기에 할당량을 기다려야 되는 필요가 없음
 - 크레딧 소모또한 과도하지 않았음.(전체 작업을 Claude Opus 5로 진행)
- PowerShell 처리와 세션 안정성은 아쉬움.
 - 작업을 맡겨둔 채 다른 일을 진행하기 쉬웠던 Codex와 달리, Kiro는 세션 중단 여부를 종종 확인해야 했음.

작년 말부터 올해 초까지 나름 핫 했던 그 당시 Antigravity가 생각나는 에이전트였음.
(준수한 크레딧, 다양한 모델 선택지, 아쉬운 세션 안정성)



Thank you!

